3.Processi di ramificazione

Contesto

Corso: Probabilità
Argomenti previsti: Funzioni generatrici e processi di ramificazione e probabilità di estinzione

Riassunto veloce

L'obiettivo di questa sezione è porre le basi per quelli che saranno i processi stocastici e le catene di Markov, sottoforma di processi di ramificazione, ovvero processi usati per descrivere l'evoluzione di popolazioni che di generazione in generazione generano una prole con probabilità uguale a quella della generazione precedenze. In particolare ci siamo concentrati sullo studio della probabilità di estinzione, che è ben più semplice di un caso generale di altro tipo.
Per poter studiare questi processi è stato necessario introdurre il concetto di funzione generatrice.

Indice degli argomenti

1. Funzioni Generatrici
2. Processi di ramificazione
3. Probabilità di estinzione

Appunti

Occupiamoci della discussione dei processi di ramificazione (o branching processes), che ci torneranno più utili avanti, nello studio delle catene di Markov.
Un **processo di ramificazione** è un processo stocastico che modella una popolazione nella quale ogni generazione si riproduce indipendentemente, seguendo una legge di probabilità comune.

Per lo studio dei processi di ramificazione è tuttavia necessario introdurre prima un paio di nozioni di funzioni generatrici.

Funzioni generatrici

Consideriamo una variabile aleatoria x che assume valori interi $0, 1, \dots k$ con probabilità $P_0, P_1, \dots P_k$, la funzione generatrice $G(s)$ di x è definita nel seguente modo.

$$G(s) \equiv \sum_{k=0}^{\infty} s^k P_k$$

riprendendo la definizione di valore medio:

$$E(F(k)) \equiv \sum_{k=0}^{\infty} F(k) P_k$$

Possiamo concludere che $G(s) = E(s^k)$.

Uteriormente avendo definito $G(s)$ tramite una somma di probabilità è evidente che $G(1) = 1$ per le proprietà di normalizzazione.
Per le proprietà delle potenze otteniamo invece $G(0) = P_0$.
Possiamo anche sfruttare la funzione generatrice per inferire la probabilità di ogni evento.

$$G'(0) = \frac{dG}{ds}|_{s=0} = \sum k s^{k-1} P_k|_{s=0} = P_1$$
$$\implies P_n = \frac{1}{n!}\frac{d^n G}{ds^n}|_{s=0}$$

Infine osserviamo che $G'(1) = \sum_k k P_k =< k >= E(k)$

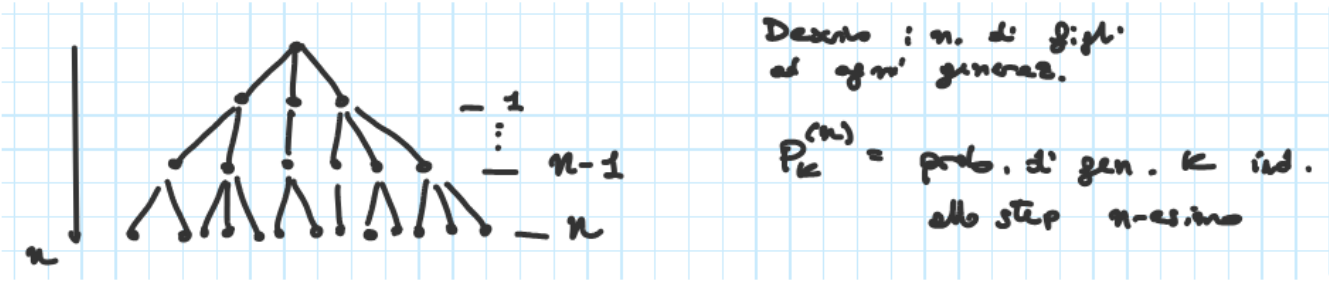
Proviamo ora a considerare $x_1, x_2, x_2, \ldots, x_n$, n variabili aleatorie **indipendenti** con funzioni generatrici $G_1(s), G_2(s), \ldots, G_n(s)$. Allora possiamo calcolare la funzione generatrice di $y = x_1 + x_2 + \ldots x_n$ come:

$$G_y(S) = \prod_{i=1}^{n} G_i(s)$$

Il risultato si dimostra per $n = 2$ e poi si procede per induzione.

Funzioni Generatrici per studiare processi di Ramificazione

Come già precedentemente discusso, un processo di ramificazione è un processo in cui in individuo genera k individui con probabilità P_k e ogni generazione successiva fa lo stesso. Si tratta dunque di una formalizzazione di processi a catena.



La domanda che viene spontaneo porsi è: se a $t = 0$ ho un individuo e le $\{P_k\}$ sono note, qual è la probabilità di avere m individui dopo n generazioni? Per n piccolo si può procedere a contare con la orza bruta, se n è grande la situazione si fa di gran lunga più complessa.
Esiste però un modo per calcolare $G_2(s)$ cioè la funzione generatrice dopo 2 generazioni, e poi $G_3(s)$ e così via fino a $G_n(s)$. La probabilità di avere m individui dopo n generazioni sarà il coefficiente davanti a s^m nella serie $G_n(s)$.

Per arrivare a ciò andiamo ad esporre ancora un risultato molto utile.
Siano $x_1, x_2, \ldots$ variabili **indipendenti e identicamente distribuite** con funzioni generatrici $G(s)$, e sia N una variabile, indipendente dalle $\{x_i\}$, con funzione generatrice $F(s)$. La funzione generatrice $G_y(s)$ della variabile $y = x_1 + x_2 + \cdots + x_N$ vale:

$$G_y(s) = F(G(s))$$

La dimostrazione è semplice e segue dai risultati precedenti:

Sia P_N la probabilità di N. Fissato N ho che $G_y^{(N)} = \prod_{i=1}^{N} G(s) = G^N(s)$.
Per N non fissato trovo:

$$G_y(s) = \sum_{N=0}^{\infty} P_N G_y^{(N)}(s) = \sum_{N=0}^{\infty} P_N G^N(s) = F(G(s))$$

■

Usando questo risultato possiamo calcolare G_n del problema di un processo di ramificazione.
Sia N_{n-1} il numero di individui all'$(n-1)$-esima generazione. Chiamiamo x_1 il numero di individui generati dal primo individuo, x_2 il numero di individui generati dal secondo individuo (della stessa generazione) e così via. All'n-esima generazione avremo:

$$N_n = x_1 + x_2 + \cdots + x_{N_{n-1}}$$

Usando il risultato appena dimostrato si ha che:

$$G_n(s) = G_{n-1}(G(s))$$

dunque:

$$G_2(s) = G(G(s)), \quad G_3(s) = G_2(G(s)) = G(G(G(s))), \quad \dots$$

Questo calcolo è matematicamente semplice ma può velocemente portare a espressioni scomode da maneggiare.

ESEMPIO: Calcoli di A.Lotka, 1920

Sfruttando i dati demografici, Lotka mostrò che negli Stati Uniti all'inizio del 1900 un maschio generava k maschi con probabilità date da:

$$P_0 = \frac{1-(\alpha+\beta)}{1-\beta}, \quad P_k = \alpha\beta^{k-1}$$

con $\alpha \simeq 0.2126$ e $\beta \simeq 0.5892$. La funzione generatrice risulta pertanto:

$$G(S) = P_0 + \alpha \sum_{k=1}^{\infty} \frac{(s\beta)^k}{\beta} = P_0 + \frac{\alpha s}{1-\beta s}$$

Cioè un'iperbole. Si può ulteriormente dimostrare che:

$$G_n(s) = \frac{A_n - B_n s}{C_n - D_n s}$$

resta sempre un'iperbole, i coefficienti $A_n, \dots$ si ottengono in maniera ricorsiva.

Probabilità di estinzione

Nonostante la forma delle funzioni generatrici possa diventare progressivamente sempre più complessa, il loro utilizzo ci permette di ricavare molto facilmente informazioni sulla probabilità di estinzione, cioè la probabilità che dopo molte generazioni non ci siano più discendenti.
Il motivo è che questo calcolo si può ricondurre a $G_n(0)$ per n grandi e non è dunque necessario ricavare la forma esplicita di $G_n(s)$.
Chiamiamo la probabità di estinzione dopo n generazioni $e_n = P_0^{(n)} = G_n(0)$, allora:

$$e_1 = G_1(0) = G_0,\ e_2 = G_2(0) = G(G(0)) = G(e_1),\ e_n = G_n(0) = \cdots = G(e_{n-1})$$

Facciamo alcune osservazioni su $G(s)$ che ci permettono di scoprire di più su e_n.
Notiamo che $G(1) = 1$, $G'(s) \geq 0$, $G''(s)P_2 \geq 0$ e $G'(1) = E(k)$, dunque $G(s)$ è una funzione concava, monotona, non decrescente.
Studiamo il caso in cui $G'(1) \leq 1$ in maniera grafica. Iterando graficamente la regola $e_{n+1} = G(e_n)$ osserviamo che e_n tende a 1, dunque l'estinzione è certa.

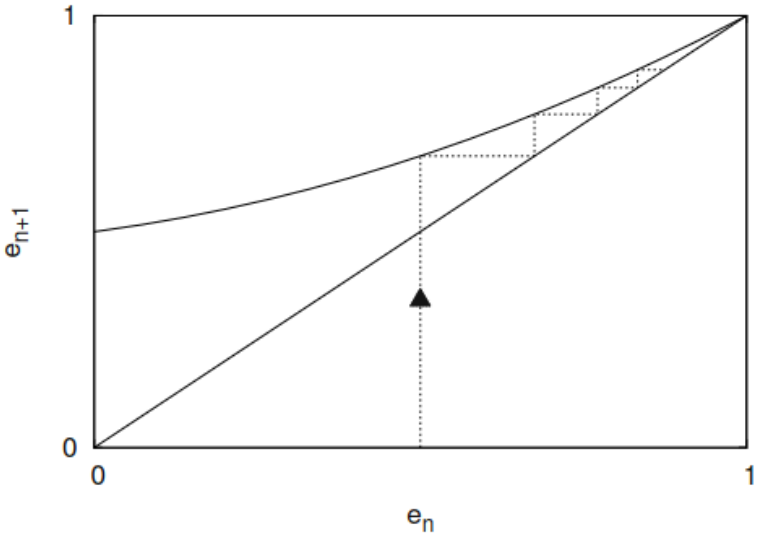


Fig. 2.1 Rappresentazione grafica dell'iterazione della regola $e_{n+1} = G(e_n)$ nel caso in cui $G'(1) < 1$ e e_n tende ad 1

Considero ora il caso $G'(1) > 1$ e procedo analogamente. $G(s)$ interseca necessariamente la bisettrice in un punto s^*, il valore di e_n tende a questo s^*, detto punto fisso e l'estinzione non è

più certa.

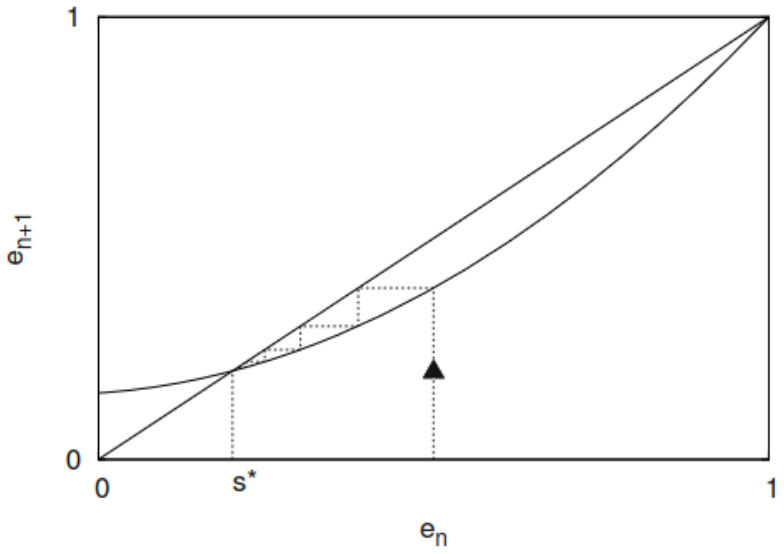


Fig. 2.2 Rappresentazione grafica dell'iterazione della regola $e_{n+1} = G(e_n)$ nel caso in cui $G'(1) > 1$ e e_n tende ad un punto fisso s^* soluzione di $s^* = G(s^*)$

Abbiamo visto che quando $E(k) < 1$ l'estinzione è certa. Nei modelli epidemiologici di tipo SIR (suscettibile, infettato, recovery), $< k >= R$ indica il numero medio di infetti per individuo ed è un parametro essenziale nello studio della probabilità di estinzione della malattia.
Attenzione! Avere $R > 1$ non significa che la malattia non si possa estinguere, significa solo che l'estinzione non è certa.

ESEMPIO: "processo di ramificazione" familiare
Ogni individuo può avere 0 o 1 figlio. Cioè:

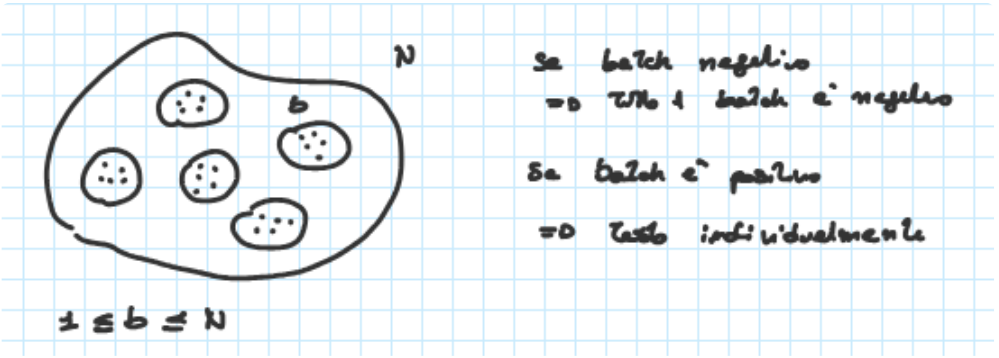
$$P_0,\ P_1,\ P_k = 0\ \forall k \geq_2$$

$$P_0 + P_1 = 1 \quad G(s) = \sum S^k P_k = P_0 + sP_1 \rightarrow \text{ retta}$$

Abbiamo che $G'(1) = P_1$. Se la probabilità di nascita di un figlio è minore del 100%, allora l'estinzione è certa. Questo risultato è estremamente intuitivo e potevamo ricavarlo anche senza questo formalismo. Di fatto il processo non era neanche un processo di ramificazione.

Forniamo in fine un esmpio carino preso sempre dallo studio di infezioni virali, per quanto non sia strettamente correlato ai processi di ramificazione.

ESEMPIO (non inerente ai processi di ramificazione): Simple Pooling
Partiamo dall'idea di voler risparmiare sul numero di test usati per una certa malattia. L'idea per fare questo è di analizzare un gruppo di individui tutti insieme. Se il batch risultasse negativo significherebbe che all'interno sono tutti negativi e siamo a posto così. In caso positivo, avremmo almeno un individuo positivo e dovremmo testare separatamente tutto il batch.
Immaginiamo di dividere N individui in batch di dimensione b. Sia p la probabilità di trovare un positivo.



Andiamo a caloclare il numero medio di test per individuo e vediamo se risulta minore rispetto a compiere il test senza pooling (senza pooling il valore medio è ovviamente 1).
Calcoliamo la probabilità che un batch sia positivo o negativo e il numero di test che andremmo a fare in ciascun caso.

$$\begin{aligned} \text{negativo} &\implies N_t = 1 \quad P_1 = (1-p)^b \\ \text{positivo} &\implies N_t = 1+b \quad P_{1+b} = 1 - P_1 \end{aligned}$$

a questo punto possiamo calcolare il numero medio di test.

$$< N_t >= (1-p)^b + (1+b)[1-(1-p)^b] = (1+b) - b(1-p)^b$$

E il numero medio per individuo:

$$\frac{< N_t >}{b} = \frac{1}{b} + 1 - (1-p)^b$$

Il simple pooling è efficace solo se questo numero è compreso tra 0 e 1.
Nel caso in cui la malattia sia rara, $p \ll 1$ possiamo approssimare il risultato $(1-p)^b \sim 1 - bp + \dots$

$$\implies \frac{< N >}{b} \sim \frac{1}{b} + bp$$

Studiamone il minimo in funzione del batch per trovarne la dimensione ottimale:

$$\frac{d}{db}\left(\frac{< N >}{b}\right) = -\frac{1}{b^2} + p = 0 \implies b^* = \frac{1}{\sqrt{p}}$$

e $\frac{<N>}{b} = 2\sqrt{p}$. Che è sempre minore di 1 per $\sqrt{p} < \frac{1}{2}$.

Domande per revisione

- [ ]

Collegamenti

- Lezione precedente: 2.Probabilità condizionata
- Concetti collegati:

- Corso: 0. Intro alla probabilità